

Atividade 2 - Transformações no Domínio Espacial e da Frequência

Aluno: Vitor Fontenele - 1700778

Repositório GitHub

Imports

```
In [1]: import numpy as np
import cv2
import matplotlib.pyplot as plt
from pathlib import Path
import os
```

Setup

```
In [2]: plt.rcParams['figure.figsize'] = (12, 8)
plt.rcParams['image.cmap'] = 'gray'

IMG_PATH = Path('gargantua.png')
OUT_DIR = Path('outputs')

def load_image(path=IMG_PATH):
    path = Path(path)
    if not path.exists():
        raise FileNotFoundError(f'Imagem não encontrada: {path.resolve()}')
    bgr = cv2.imread(str(path), cv2.IMREAD_UNCHANGED)
    if bgr is None:
        raise ValueError(f'Não foi possível ler a imagem: {path.resolve()}')
    if bgr.ndim == 2:
        return bgr
    return cv2.cvtColor(bgr, cv2.COLOR_BGR2RGB)
```

```
def to_gray(img):
    if img.ndim == 2: return img
    return (0.299 * img[:, :, 0] + 0.587 * img[:, :, 1] + 0.114 * img[:, :, 2]).astype(np.float32)

def save_image(filename, img, out_dir=OUT_DIR):
    out_dir = Path(out_dir)
    out_dir.mkdir(parents=True, exist_ok=True)
    out_path = out_dir / filename
    arr = np.clip(img, 0, 255).astype(np.uint8)
    if arr.ndim == 3:
        arr = cv2.cvtColor(arr, cv2.COLOR_RGB2BGR)
    cv2.imwrite(str(out_path), arr)
    return out_path

def show_grid(images, titles, cols=3):
    n = len(images)
    rows = (n + cols - 1) // cols

    _, axes = plt.subplots(rows, cols, figsize=(cols * 5, rows * 5))
    axes = axes.flatten() if n > 1 else [axes]

    for i in range(len(axes)):
        if i < n:
            axes[i].imshow(images[i], vmin=0, vmax=255)
            axes[i].set_title(titles[i])
            axes[i].axis('off')

    plt.tight_layout()
    plt.show()

def initialize():
    img = load_image()
    img_gray = to_gray(img)
    save_image('gargantua_gray.png', img_gray, '.')
    show_grid([img, img_gray], ['Original', 'Cinza'], cols=2)

initialize()
```

Original



Cinza



Questão 1 - Convolução

Preparação para Convolução: Definição de filtros e função

```
In [3]: kernels = {  
    "h1": np.array([  
        [ 0,  0, -1,  0,  0],  
        [ 0, -1, -2, -1,  0],  
        [-1, -2, 16, -2, -1],  
        [ 0, -1, -2, -1,  0],  
        [ 0,  0, -1,  0,  0]  
    ], dtype=np.float32),  
  
    "h2": (1/256) * np.array([  
        [1,  4,  6,  4,  1],  
        [4, 16, 24, 16,  4],  
        [6, 24, 36, 24,  6],  
        [4, 16, 24, 16,  4],  
        [1,  4,  6,  4,  1]  
    ], dtype=np.float32),
```

```
"h3": np.array([
    [-1, 0, 1],
    [-2, 0, 2],
    [-1, 0, 1]
], dtype=np.float32),

"h4": np.array([
    [-1, -2, -1],
    [ 0,  0,  0],
    [ 1,  2,  1]
], dtype=np.float32),

"h5": np.array([
    [-1, -1, -1],
    [-1,  8, -1],
    [-1, -1, -1]
], dtype=np.float32),

"h6": (1/9) * np.array([
    [1, 1, 1],
    [1, 1, 1],
    [1, 1, 1]
], dtype=np.float32),

"h7": np.array([
    [-1, -1,  2],
    [-1,  2, -1],
    [ 2, -1, -1]
], dtype=np.float32),

"h8": np.array([
    [ 2, -1, -1],
    [-1,  2, -1],
    [-1, -1,  2]
], dtype=np.float32),

"h9": (1/9) * np.eye(9),

"h10": (1/8) * np.array([
    [-1, -1, -1, -1, -1],
```

```

        [-1, 2, 2, 2, -1],
        [-1, 2, 8, 2, -1],
        [-1, 2, 2, 2, -1],
        [-1, -1, -1, -1, -1]
    ], dtype=np.float32),

    "h11": np.array([
        [-1, -1, 0],
        [-1, 0, 1],
        [0, 1, 1]
    ], dtype=np.float32)
}

def convolution(imagem, filtro):
    i_h, i_w = imagem.shape
    f_h, f_w = filtro.shape

    pad_h, pad_w = f_h // 2, f_w // 2

    imagem_pad = np.pad(imagem, ((pad_h, pad_h), (pad_w, pad_w)), mode='constant', constant_values=0)

    saida = np.zeros_like(imagem, dtype=np.float32)

    for i in range(i_h):
        for j in range(i_w):
            regioao = imagem_pad[i:i+f_h, j:j+f_w]

            saida[i, j] = np.sum(regiao * filtro)

    return saida

```

Rodando

```

In [4]: img = load_image('gargantua_gray.png')
        resultados = []
        titulos = []

        for nome, filtro in kernels.items():
            print(f"Aplicando {nome}...")

```

```
img_filtrada = convolution(img, filtro)

img_visualizacao = np.abs(img_filtrada)

resultados.append(img_visualizacao)
titulos.append(nome)

save_image(f'resultado_{nome}.png', img_visualizacao)

show_grid(resultados, titulos)
```

Aplicando h1...

Aplicando h2...

Aplicando h3...

Aplicando h4...

Aplicando h5...

Aplicando h6...

Aplicando h7...


Aplicando h8...

Aplicando h9...

Aplicando h10...

Aplicando h11...


h1




h2




h3



h4




h5




h6




h7





h8



h9






h10



h11



Questão 2 - FFT

Funções engine para FFT

```
In [5]: def aplicar_fft(img):  
        fft_original = np.fft.fft2(img)  
        fft_centralizada = np.fft.fftshift(fft_original)  
        return fft_centralizada  
  
        def aplicar_ifft(espectro_centralizado):
```



```
fft_descentralizada = np.fft.ifftshift(espectro_centralizado)
img_reconstruida = np.fft.ifft2(fft_descentralizada)
return np.abs(img_reconstruida)

def calcular_espectro_visual(espectro):
    magnitude = np.abs(espectro)
    visualizacao = 20 * np.log(magnitude + 1)
    return visualizacao

def criar_grade_distancias(shape):
    linhas, colunas = shape
    centro_u, centro_v = linhas // 2, colunas // 2
    u, v = np.ogrid[:linhas, :colunas]
    distancias = np.sqrt((u - centro_u)**2 + (v - centro_v)**2)
    return distancias

def filtro_passa_baixa(shape, raio):
    dist = criar_grade_distancias(shape)
    return (dist <= raio).astype(np.float32)

def filtro_passa_alta(shape, raio):
    dist = criar_grade_distancias(shape)
    return (dist > raio).astype(np.float32)

def filtro_passa_faixa(shape, raio_interno, raio_externo):
    dist = criar_grade_distancias(shape)
    mascara = (dist >= raio_interno) & (dist <= raio_externo)
    return mascara.astype(np.float32)

def filtro_rejeita_faixa(shape, raio_interno, raio_externo):
    passa_faixa = filtro_passa_faixa(shape, raio_interno, raio_externo)
    return 1.0 - passa_faixa

def comprimir_por_fourier(espectro, percentual_corte=90):
    magnitude = np.abs(espectro)
    limiar = np.percentile(magnitude, percentual_corte)
    espectro_comprimido = np.copy(espectro)
    espectro_comprimido[magnitude < limiar] = 0
    return espectro_comprimido
```

```
def get_file_size(filepath):  
    if os.path.exists(filepath):  
        return os.path.getsize(filepath) / 1024  
    return 0
```


Rodando

Filtros

```
In [6]: shape = img.shape  
        espectro = aplicar_fft(img)  
  
        cenarios = [  
            {"nome": "1", "r": 15, "r_in": 5, "r_out": 25},  
            {"nome": "2", "r": 60, "r_in": 30, "r_out": 80},  
            {"nome": "3", "r": 150, "r_in": 100, "r_out": 200}  
        ]  
  
        for c in cenarios:  
            r = c["r"]  
            r_in, r_out = c["r_in"], c["r_out"]  
  
            mascaras_cenario = {  
                f"Passa-Baixa (r={r})": filtro_passa_baixa(shape, r),  
                f"Passa-Alta (r={r})": filtro_passa_alta(shape, r),  
                f"Passa-Faixa ({r_in}-{r_out})": filtro_passa_faixa(shape, r_in, r_out),  
                f"Rejeita-Faixa ({r_in}-{r_out})": filtro_rejeita_faixa(shape, r_in, r_out)  
            }  
  
            resultados_imgs = []  
            titulos_imgs = []  
  
            for nome, mascara in mascaras_cenario.items():  
                espectro_filtrado = espectro * mascara  
  
                img_reconstruida = aplicar_ifft(espectro_filtrado)  
  
                resultados_imgs.append(img_reconstruida)  
                titulos_imgs.append(nome)
```

```
save_image(f"fourier_{c['nome']}_{{nome.split(' ')[0]}}.png", img_reconstruida)

show_grid(resultados_imgs, titulos_imgs, cols=4)
```



Análise dos Filtros

A análise dos resultados obtidos nos três cenários de filtragem revela como a manipulação do raio de corte (r) e das bandas de frequência (r_{in} , r_{out}) impacta diretamente a reconstrução espacial da imagem do Gargantua.

Cenário 1 (Agressivo - Núcleos Curtos): Neste cenário, observou-se a maior perda de fidelidade visual. O filtro **Passa-Baixa** atuou de forma severa, mantendo apenas as frequências próximas ao centro, o que resultou em uma imagem excessivamente embaçada, onde o ruído de

alta frequência foi eliminado, mas a definição do buraco negro foi perdida. O **Passa-Alta**, ao bloquear quase todo o centro, gerou uma imagem escura com bordas muito espessas. Uma percepção "psicodélica" foi percebida nos filtros **Passa-Faixa** e **Rejeita-Faixa**.

Cenário 2 (Moderado - Equilíbrio): Este cenário apresentou o melhor equilíbrio para a extração de características. No **Passa-Alta** e no **Passa-Faixa**, embora a imagem resultante seja naturalmente mais escura pela remoção das baixas frequências, brilho global, foi possível preservar e identificar o contorno e a silhueta do disco de acreção do Gargantua de forma mais nítida que nos demais cenários. Notou-se que o filtro **Rejeita-Faixa** neste estágio apresentou um comportamento visualmente similar ao Passa-Baixa do cenário anterior, pois ao rejeitar uma faixa intermediária considerável, ele acaba priorizando as frequências muito baixas, resultando em uma suavização controlada que ainda permite reconhecer a estrutura principal.

Cenário 3 (Suave - Alta Frequência): No cenário de núcleos amplos, as alterações foram sutis. O **Passa-Baixa** e o **Rejeita-Faixa** apresentaram resultados muito próximos à imagem original, indicando que a maior parte da energia da imagem está contida dentro do raio de 150 pixels. O **Passa-Faixa** e o **Passa-Alta**, por sua vez, isolaram apenas os detalhes mais finos e contornos afiados, com baixíssima presença de ruído ou artefatos de interferência. As silhuetas aqui são mais nítidas e "limpas", porém menos informativas sobre a estrutura volumétrica do objeto do que no Cenário 2, servindo primariamente para realce de detalhes finos.

```
In [7]: testes_percentual = [90, 95, 99, 99.9]
size_orig = get_file_size('gargantua_gray.png')

for p in testes_percentual:
    espectro_comprimido = comprimir_por_fourier(espectro, percentual_corte=p)
    img_comprimida = aplicar_ifft(espectro_comprimido)

    figure_name = f'compressao{p}.png'
    save_image(figure_name, img_comprimida)
    size_comp = get_file_size(OUT_DIR / figure_name)

    fig, axes = plt.subplots(1, 3, figsize=(20, 5))

    axes[0].imshow(img_comprimida, cmap='gray')
    info_texto = (f'Corte: {p}%\n'
                  f'Tamanho Original: {size_orig:.2f} KB\n'
                  f'Tamanho Comprimido: {size_comp:.2f} KB\n'
                  f'Economia: {100 - (size_comp/size_orig*100):.1f}%')

    axes[0].set_title(f'Gargantua Comprimido\n{info_texto}', fontsize=10, loc='left')
```

```

axes[0].axis('off')



# histograma comparativo
axes[1].hist(img.ravel(), bins=256, range=[0,256], color='green', alpha=0.3, label='Original')
axes[1].hist(img_comprimida.ravel(), bins=256, range=[0,256], color='purple', alpha=0.7, label='Comprimida')
axes[1].legend()

esp_vis_comp = calcular_espectro_visual(espectro_comprimido)
axes[2].imshow(esp_vis_comp, cmap='magma') # 'magma' fica top para espectro
axes[2].set_title(f'Espectro c/ {p}% cortado')
axes[2].axis('off')


plt.tight_layout()
plt.show()

```


Gargantua Comprimido
 Corte: 90%
 Tamanho Original: 360.25 KB
 Tamanho Comprimido: 379.91 KB
 Economia: -5.5%




Gargantua Comprimido
Corte: 95%
Tamanho Original: 360.25 KB
Tamanho Comprimido: 352.89 KB
Economia: 2.0%




Espectro c/ 95% cortado





Gargantua Comprimido
Corte: 99%
Tamanho Original: 360.25 KB
Tamanho Comprimido: 294.16 KB
Economia: 18.3%




Espectro c/ 99% cortado



Gargantua Comprimido
Corte: 99.9%
Tamanho Original: 360.25 KB
Tamanho Comprimido: 211.27 KB
Economia: 41.4%



Espectro c/ 99.9% cortado



Análise da Compressão por Limiar de Magnitude

Nesta etapa, explorou-se a capacidade da Transformada de Fourier em compactar informações através do descarte de coeficientes de baixa magnitude. A técnica baseia-se no fato de que a maior parte da energia e das informações estruturais de uma imagem está concentrada em poucos coeficientes de alta magnitude, permitindo uma redução drástica de dados com perda mínima de percepção visual.

Metodologia de Comparação: Para validar a eficiência da compressão, utilizou-se uma abordagem comparativa em três frentes: a visualização do **espectro de magnitude logarítmica**, que revela a quantidade de coeficientes descartados; a análise de **histogramas de intensidade**, para medir o impacto na distribuição de tons de cinza; e a aferição do **tamanho dos arquivos em disco**, comparando o peso das imagens reconstruídas em relação ao arquivo original para quantificar a economia real de armazenamento.

Fidelidade Visual e Comportamento do Espectro: Observou-se que a quantidade de informação visual no espectro diminui bruscamente conforme aumentamos o percentual de corte. Nos níveis de 90% e 95%, a imagem reconstruída do Gargantua permanece visualmente muito próxima à original, o que evidencia uma alta redundância de dados. Entretanto, a partir de 99%, a imagem apresenta um embaçamento severo. É notável que a diferença visual e de dados entre 99% e 99.9% é massiva, pois a compressão se torna extremamente agressiva no último nível, onde apenas os componentes mais fundamentais da imagem, são preservados.

Análise dos Histogramas: A comparação entre os histogramas revela que, conforme a compressão aumenta, o valor máximo das frequências de intensidade tende a diminuir e o delta, representando a variação de tons, fica visivelmente menor. Nas imagens mais comprimidas, como no caso de 99.9%, o histograma reflete a simplificação da imagem. Como há menos detalhes e variações bruscas, a

distribuição de pixels se torna menos espalhada e mais concentrada em faixas específicas de cinza, o que confirma a perda de contraste e nitidez observada visualmente.

Eficiência de Armazenamento e a Curiosidade dos 90%: Um fenômeno interessante ocorreu no nível de 90% de corte, no qual o arquivo final apresentou um aumento de tamanho de aproximadamente 5.5% em relação ao original, enquanto em 95% a redução foi sutil, cerca de 2%. Isso acontece devido a uma característica técnica: ao zerar 90% dos coeficientes de Fourier, introduzimos pequenas oscilações matemáticas na imagem reconstruída, conhecidas como artefatos de *ringing*.

Para o olho humano, o resultado parece quase idêntico, mas para o algoritmo de armazenamento do arquivo PNG, essas micro-oscilações são interpretadas como ruído ou novos detalhes que precisam ser guardados com precisão. Como o PNG é um formato que não aceita perdas, ele acaba gastando mais bytes para descrever esse ruído matemático do que gastaria com a imagem original lisa. A economia real torna-se relevante apenas em níveis extremos: o ganho de 85 KB observado entre 90% e 99% foi praticamente igualado pelo salto de apenas 0.9%, de 99% para 99.9%, que economizou mais 83 KB. Isso demonstra que a compressão baseada em Fourier é extremamente poderosa para reduzir o peso de arquivos, desde que se aceite uma simplificação visual maior da imagem.